고정 지그 환경에서 홀 랜드마크와 CAD 치수 대조를 이용한 굴착기 도어 형상군 식별

Identification of Excavator Door Shape Classes Using Hole Landmarks and CAD Dimension Matching in a Fixed Jig

(저자·소속·교신저자: 최종 파일 업로드 시 작성)

ABSTRACT

Excavator side doors of different models look alike but differ in the CAD distance D between two corner holes. In a fixed jig, we detect six hole landmarks with a heatmap network, convert the corner-hole pixel distance to millimeters with a jig scale, and match it to CAD values, abstaining beyond 30 mm. In a retrospective evaluation of 361 production doors (7,104 images), a laboratory-trained detector abstained on all 74 fold-0 test doors. With eight field images for training and eight for selection, all 361 doors were identified in five-fold door-disjoint cross-validation, and all 133 doors in a temporal split. Pixel-width residuals to CAD stayed within 1.14%, whereas a depth-plane distance misclassified 16 doors and abstained on 13. An RGB CNN identified 360 and 132 doors. Six doors of an unregistered class 266 mm from the nearest CAD value were rejected, then identified after registering its CAD value.

Key Words: Excavator door, Part identification, Hole landmark, CAD dimension, Field adaptation, Abstention

1. 서 론

다품종 혼류 생산에서는 작업 대상 부품의 품종을 먼저 식별해야 용접·조립 조건과 로봇 작업 경로를 선택할 수 있다. 굴착기 측면 도어는 기종(E25·E30·E38)과 위치(좌·우, 앞·뒤)에 따라 여러 형상군으로 나뉘지만, 같은 공정의 박판 프레스 부품이므로 외관과 표면 상태가 서로 비슷하다. 이러한 부품의 영상 식별에는 외관 기반 합성곱 신경망(CNN)[1]이 널리 쓰인다. 외관 분류기는 현장 영상으로 학습하면 높은 정확도를 얻을 수 있다. 그러나 판정 근거가 특정 치수와 직접 연결되지 않고, 고정된 출력 클래스로 학습한 분류기는 새 품종을 추가할 때 현장 영상을 모아 다시 학습해야 하며, 학습하지 않은 품종도 기존 품종 중 하나로 출력한다[2,5,6].

도어 형상군의 차이는 설계 치수로 정의된다. 대상 도어는 세로 프레임 상단의 두 모서리 홀 사이 거리 D가 형상군마다 다르다(Table 1). 따라서 영상에서 두 홀의 위치를 찾아 D를 측정하고 CAD 값과 대조하면, 판정 단계에서 클래스별 분류 가중치 대신 설계 치수로 형상군을 결정할 수 있다. 등록된 어느 CAD 값과도 맞지 않는 측정은 판정을 보류하고, 홀 배치가 같고 치수가 충분히 떨어진 새 품종은 CAD 값을 등록하여 추가할 수 있다. 판금 부품에서는 합성 데이터로 학습한 코너 검출로 위치를 추정하고 실제 생산 영상에서 평가한 연구[3]와 CAD 정보로 홀·슬롯 치수를 측정한 연구[4]가 있다. 본 연구는 이러한 특징점 검출과 CAD 치수를 유사 품종의 식별 판정에 결합하고, 측정 잔차를 형상군 사이의 판정 여유와 비교하며, 조건별 실패 양상을 실제 생산 도어로 분석한다는 점에서 다르다.

이 방식을 현장에 적용하려면 세 가지를 확인해야 한다. 첫째, 홀 검출기 자체는 RGB 영상에서 학습하므로 실험실에서 학습한 검출기가 배경과 조명이 다른 현장으로 전이되는지, 전이되지 않는다면 현장 주석을 얼마나 추가해야 하는지 알아야 한다. 둘째, 측정 거리의 잔차가 인접 형상군과의 치수 간격 안에 들어오는지 확인해야 한다. 셋째, 외관 분류기와 비교하여 어떤 조건에서 차이가 나는지 확인해야 한다.

본 연구는 홀 랜드마크 검출, 볼트 홀 배열의 기하 검사, 거리–CAD 대조로 이루어진 형상군 식별 절차를 구성하고, 한 사업장의 고정 지그에서 수집한 실제 생산 도어 361개의 영상으로 위 세 가지를 후향적으로 평가하였다. 실험실 영상만으로 학습한 검출기가 현장의 모서리 홀을 찾지 못하는 것을 확인하였고, 같은 현장에서 폴드마다 학습용 8장과 모델 선택용 8장의 현장 좌표를 추가한 모델이 5겹 교차검증의 모든 도어를 식별함을 보였다. 같은 검출점에서 픽셀 폭 기반 거리와 깊이 평면 기반 거리의 잔차와 실패 양상을 비교하였다. 외관 CNN 과는 무작위 분할과 시간 분할에서 비교하고, 판정 비율과 오류율의 관계를 탐색적으로 분석하였다. 또한 등록 치수와 충분히 떨어진 미등록 형상군 하나(E23 LH FRT)에 대해 거절과 CAD 등록 후 식별을 확인하였다.

2. 관련 연구

외관 기반 식별. 잔차 학습 구조[1]는 산업 부품 분류의 기본 백본으로 널리 쓰인다. Prünte 등[2]은 외관이 매우 유사한 항공기 엔진 튜브를 2 차원 영상과 3 차원 점군으로 식별하는 방법을 비교하였다. 이를 통해 유사 부품에서는 표현의 선택이 성능을 좌우함을 보였다. 본 연구는 외관 전체 대신 설계 치수로 정의된 국소 특징을 표현으로 사용한다.

판금 특징점과 CAD 기반 측정. Behnen 등[3]은 합성 데이터로 학습한 코너 검출로 판금의 위치를 추정하고 실제 생산 영상에서 평가하였다. Lin 등[4]은 CAD(PRT) 파일의 특징 정보를 이용해 판금 부품의 홀·슬롯 치수를 영상으로 측정하였다. 이들은 위치 추정과 치수 검사를 다루며, 본 연구는 측정 치수를 품종 식별의 판정 근거로 사용한다는 점에서 다르다.

히트맵 기반 랜드마크 검출. 특징 피라미드[7]와 간결한 복원부를 갖는 히트맵 회귀[8]는 소수 점의 위치 추정에 널리 쓰인다. 본 연구는 이 구조를 도어 홀 6 점의 검출에 적용하며, 구조 자체의 새로움을 주장하지 않는다.

판정 보류와 미등록 품종. 보류를 허용하는 분류는 판정 비율과 정확도를 함께 보고해야 한다[9]. 학습하지 않은 클래스의 입력을 걸러내는 문제는 개방 집합 인식[5,10]과 분포 외 입력 검출[6]로 다루어진다. CNN 에서는 소프트맥스 최대값의 임계값이 기준선으로 쓰이며[6], OpenMax[10]처럼 분류기를 개방 집합으로 확장하는 방법도 있다. 본 연구의 CNN 비교군은 고정된 8 출력 분류기와 소프트맥스 임계값 기준선이며, 개방 집합 CNN 과의 비교는 다루지 않는다. CAD 대조 방식은 등록된 치수와의 거리로 보류를 판단한다.

3. 제안 방법

3.1 대상 형상군과 CAD 기준 치수

대상은 굴착기 측면 도어 8 개 형상군이다(Table 1). E30 과 E38 의 우측 도어는 같은 형상이므로 한 형상군으로 묶었다. 기준 치수 D 는 힌지 측과 래치 측 상단 모서리 홀(Ø6) 중심 사이의 CAD 거리이며, 8 개 형상군 모두 값이 다르다. 판정은 측정 거리와 가장 가까운 CAD 값을 선택하고, 그 차이가 30 mm 를 넘으면 보류한다. 따라서 형상군 c 가 올바르게 판정되는 측정 거리는 인접 형상군과의 중간값과 ±30 mm 보류 경계 중 안쪽 범위이다. 이를 CAD 값에 대한 상대 잔차로 나타낸 것이 Table 1 의 판정 여유이다. 절대 간격이 가장 작은 쌍은 E25 LH FRT–E30 LH FRT(41 mm)이다. 그러나 상대 여유는 E38 LH RR(±2.22%, 보류 경계)과 E30/E38 RH(−2.30%, E25 LH RR 과의 중간값)가 가장 좁다.

Table 1 Door shape classes, CAD distance D, field data, and correct-decision band

Class	D_CAD (mm)	Doors	Images	Band (%)
E25 LH FRT	724	9	180	−4.14 / +2.83
E30 LH FRT	765	44	867	−2.68 / +3.07
E38 LH FRT	812	21	410	−2.89 / +3.69
E25 RH	886	68	1,343	−3.39 / +3.39
E25 LH RR	1,037	70	1,388	−2.89 / +2.41
E30/E38 RH	1,087	70	1,398	−2.30 / +2.76
E30 LH RR	1,158	50	984	−2.59 / +2.59
E38 LH RR	1,352	29	534	−2.22 / +2.22
Total	–	361	7,104	–

3.2 홀 랜드마크 검출

검출기는 ImageNet 으로 초기화한 ResNet18[1] 인코더와 특징 피라미드형 복원부[7,8]로 구성하였다. 입력 RGB 영상을 종횡비를 유지하여 1280×768 로 변환하고 입력의 1/4 해상도로 세 채널의 히트맵을 출력한다. 첫 채널은 래치 측 볼트 홀 4 개를 다중 봉우리로, 나머지 두 채널은 힌지 측과 래치 측 모서리 홀을 각각 표현한다(Fig. 1). 정답 히트맵은 표준편차 2 의 가우시안이다. 손실은 정답 응답에 비례하는 가중치(1+20H)를 둔 평균 제곱 오차이며, 보이지 않는 점은 손실에서 제외하였다. 증강은 임의 회전(±180°), 크기(0.8~1.15), 좌우 반전, 밝기·흐림 변화를 사용하였다. AdamW(학습률 1×10^{-4}, 코사인 감쇠), 배치 4, 80 epoch 로 학습하였다. 응답 0.15 이상의 극대점을 볼트 채널에서 최대 4 개, 두 모서리 채널에서 1 개씩 검출점으로 취한다.

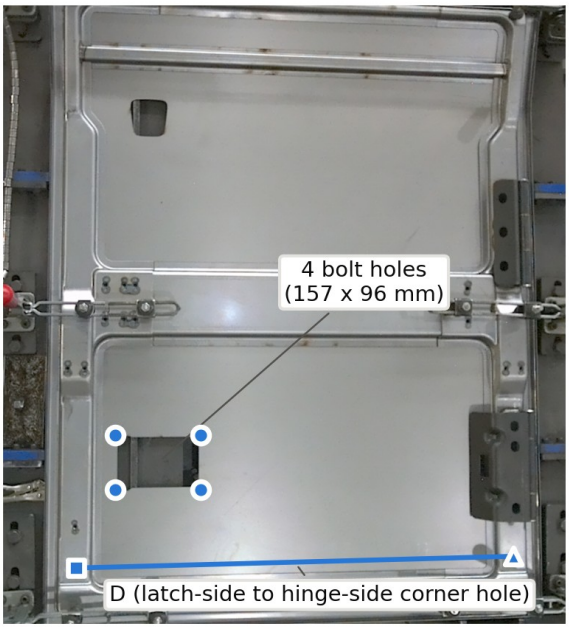


Fig. 1 (a) Field image of an E38 LH FRT door with the six detected holes and the measured distance D; (b) decision pipeline. The scale S is fit on training sessions only

3.3 기하 검사

네 볼트 홀은 CAD 상 157×96 mm 직사각형을 이룬다. 검출된 네 점에서 장변과 단변 방향을 정하고, 두 방향의 픽셀 길이를 각 CAD 피치로 나눈 축척의 차이가 18%를 넘으면 배열을 기각한다. 통과한 배열의 축척과 방향을 기준으로, 래치 측 모서리 홀이 설계상 위치 범위에 있는지와 두 모서리 홀이 볼트 배열의 서로 반대편에 있는지 검사한다. 이 검사를 통과하지 못하거나 모서리 홀이 검출되지 않으면 판정을 보류한다. 검사는 전체 도어의 분할 마스크를 요구하지 않는다.

3.4 거리 추정

픽셀 폭 방식. 두 모서리 홀의 영상 좌표 p_h, p_l과 수평 초점거리 f_x로 $D = S \cdot \| p_h - p_l \| / f_x$를 계산한다. 도어가 광축에 수직인 평면에 놓이면 S는 카메라–도어 거리에 해당하며, 고정 지그에서는 S를 상수로 둘 수 있다. S는 학습 세션에서 CAD 거리와 정규화 픽셀 거리의 비를 세션별 중앙값으로 구한 뒤 카메라별 중앙값으로 결정하였다. 이상적인 전면 평행 조건에서 실제 촬영 거리가 Z이면 D 추정값과 실제값의 비는 S/Z이다. 따라서 기준 거리에서 ΔZ만큼 멀어지면 상대 잔차는 $-\Delta Z/(S+\Delta Z)$가 되고, 작은 변화에서는 촬영 거리의 상대 변화와 비슷한 크기로 나타난다.

깊이 평면 방식. 검출점들의 볼록 껍질 내부 깊이 화소를 역투영하여 평면을 맞추고, 잔차 10 mm 이내의 점으로 평면을 다시 추정한다. 두 모서리 홀의 시선을 평면과 교차시켜 3차원 거리 d_{3D}를 구하고, 학습 세션에서 구한 상수 K로 $D = K \cdot d_{3D}$를 계산한다.

3.5 판정과 보류

측정 D와 각 형상군 CAD 값의 차가 가장 작은 형상군을 선택하고, 그 차가 30 mm를 넘으면 보류한다. 도어 한 개의 세션 판정은 판정된 영상들의 최빈값으로 정하며, 동률이거나 모두 보류이면 세션도 보류한다. 이 규칙은 품종이 등록되었는지를 직접 아는 것이 아니라, 측정값이 등록된 모든 CAD 값에서 30 mm 넘게 떨어졌는지를 검사한다. 따라서 미등록 품종은 D가 모든 등록값과 충분히 떨어져 있을 때 보류되며, D가 어느 등록값의 ±30 mm 안에 있으면 그 형상군으로 판정될 수 있다. 같은 홀 배치와 기하 검사를 만족하고 기존 값과 충분히 떨어진 새 품종은 CAD 값 D를 등록하여 판정 대상에 추가할 수 있다.

4. 실험 방법

4.1 현장 데이터

데이터는 2026년 8월 27일부터 10월 29일까지 도어 용접 공정의 고정 지그 상부에 설치한 ZED X Mini 스테레오 카메라 1대(1920×1200, 좌안 RGB와 정합 깊이)로 수집하였다. 작업자가 도어를 지그에 거치하고 형상군을 선택하면 2초 간격으로 영상이 저장된다. 한 세션은 실제 생산 작업 중의 도어 1개에 해당하므로, 361세션은 서로 다른 실물 도어 361개이다. 포함된 361세션에는 원 수집 36,142쌍이 기록되어 있으며, 이 중 로컬에 보유한 7,376쌍에서 세션당 최대 20장을 균등 추출하여 7,104쌍을 고정하였다. 따라서 직접 평가한 자료는 이 추출 표본이다. 정답은 작업자가 입력한 형상군이다. 작업자 입력과 기존 판별 결과가 불일치한 세션은 저자가 전수 육안 확인하였고, 입력 오류로 확인된 11세션과 촬영 무효 7세션은 제외하였다. 입력 오류 중 6세션은 대상 밖 형상군인 E23 LH FRT 도어였으며, 이들은 5.5절의 미등록 품종 부가 실험에만 사용하였다.

4.2 분할과 현장 좌표 주석

세션을 형상군별로 층화하여 다섯 그룹으로 나누었다. 같은 도어의 영상은 한 그룹에만 속한다. 5겹 교차검증에서는 그룹 k를 시험, 그룹 k+1(mod 5)을 검증, 나머지 세 그룹을 학습에 사용하였다. 다섯 폴드의 시험 결과를 모으면 모든 도어가 그 도어를 학습하지 않은 모델로 한 번씩 판정된다(out-of-fold, OOF). 시간 분할에서는 10월 3일 이전 228세션을 학습(193)과 검증(35)에, 이

후 133 세션을 시험에 사용하였다. 시간 분할의 시험 도어는 361 개의 일부이며 새로운 모집단은 아니다.

실험실 영상 118 장(1920×1080)에는 6 점의 위치를 수동으로 주석하여 94 장을 학습, 24 장을 검증에 사용하였다. 현장 좌표는 모델 출력과 무관하게 형상군×그룹마다 한 세션의 가운데 영상을 골라 40 장을 주석하였다. 저자 1 인이 240 점을 주석하는 데 16 분 23 초(장당 평균 24.6 초)가 걸렸다. 각 폴드에서 40 장은 시험 그룹 8 장, 검증 그룹 8 장, 학습 그룹 24 장으로 나뉜다. 학습 그룹 24 장에서 형상군당 1 장을 고정된 해시 순서로 골라 8 장을 학습에 쓰고, 검증 그룹 8 장으로 체크포인트를 선택하였다. 같은 평균으로 환산하면 학습용 8 장은 약 3.3 분, 모델 선택용 8 장을 합한 16 장은 약 6.6 분이다. 폴드 0 에서는 형상군당 2 장, 3 장을 쓴 16 장, 24 장 모델도 학습하여 현장 학습량의 영향을 보았다(Table 3). 시간 분할에서는 학습 기간에 속한 현장 좌표 24 장을 모두 학습에, 검증 기간의 3 장을 체크포인트 선택에 사용하였다. 이 24 장에는 E30 LH RR 이 포함되지 않았다.

4.3 비교 조건

비교 조건과 각 조건이 사용한 감독 정보를 Table 2 에 정리하였다. 홀 방법의 현장 적응 모델은 실험실 94 장에 현장 좌표를 더해 폴드마다 새로 학습하였다. 실험실 전용 모델은 현장 좌표 없이 실험실 검증 24 장으로 선택하였다. 고정 참조 모델은 데이터 기간 시작 전인 2026 년 8 월 26 일에 학습을 마친 검출기이다. 실험실 94 장과 현장 13 장으로 학습하고 실험실 24 장과 현장 3 장으로 검증하였으며, 현장 16 장은 모두 지그 설치 이전 시험 촬영 세션 1 개(2026 년 8 월 10 일)에서 나왔다. 본 데이터의 어떤 세션도 학습에 포함하지 않았으므로 모든 폴드와 시간 분할에서 재학습 없이 같은 가중치로 평가하였다. 모든 홀 조건은 검출 가중치만 다르고 이후의 검사·보정·판정은 동일하며, 축척 S 는 각 분할의 학습 세션으로만 정하였다. 형상군 라벨은 S 보정과 형상군별 현장 좌표 표본 선택에 사용되었다.

외관 비교는 ImageNet 으로 초기화한 ResNet18 분류기를 각 분할의 학습 세션 형상군 라벨로 학습하였다. 입력은 448×448 RGB 와 RGB 에 Canny 엣지를 더한 4 채널(RGBE)이다. Adam(학습률 3×10^{-4})으로 최대 40 epoch 학습하고 검증 세션의 균형 정확도로 선택하였다. 보류가 필요한 비교에서는 검증 영상의 최소 약 95%를 수락하도록 정한 소프트맥스 최대값 임계값[6]을 하나의 운용점으로 사용하였다. 신뢰도 값의 동점 때문에 실제 검증 수락률은 95.0~96.0%였고, 임계값은 0.99955~1.0 으로 1 에 매우 가까웠다(RGB 폴드 0: 0.9999998808, 검증 수락률 96.01%; 시간 분할: 0.9999995232, 95.62%).

Table 2 Compared methods and the supervision each uses (per fold)

Method	Field class labels	Field points (train / select)	Lab points (train / val)
RGB / RGBE CNN	Classifier training and selection	–	–
Hole, lab only	Scale S	0 / 0	94 / 24
Hole, field 8 (main)	Scale S, point sampling	8 / 8	94 / 24 (monitor)
Hole, field 24 (fold 0)	Scale S, point sampling	24 / 8	94 / 24 (monitor)
Hole, temporal	Scale S, point sampling	24 / 3	94 / 24 (monitor)
Hole, frozen reference	Scale S	13 / 3 (pre-period)	94 / 24

4.4 평가 절차와 지표

모든 정확도는 보류를 분모에 포함한 전체 입력 기준이다. 판정 비율은 형상군을 출력한 입력의 비율이다. 영상 단위와 세션(도어) 단위 결과를 함께 보고하고, 세션 정확도에는 Wilson 95% 신뢰구간을 붙였다. 세션 판정은 한 도어의 최대 20 장에 대한 최빈값이므로 단일 영상의 실시간 판정과 구분된다. 방법 간 차이는 같은 세션의 대응 결과로 비교하고 세션 그룹 bootstrap 95% 구간을 계산하였다. 검출 정확도는 사람이 주석한 점과 원본 해상도 8 화소 이내로 일치하는 비율(PCK8)로 평가하였다. 거리의 정답은 실물 실측값이 아니라 각 형상군의 CAD 값이므로, 거리 오차는 CAD 기준 상대 잔차 $D/D_{CAD}-1$ 로 나타냈다.

본 연구는 후향적 평가이다. 실험실 영상만으로 학습한 검출기의 첫 시험이 실패한 것을 확인한 뒤 현장 적응을 설계하였다. 이어 폴드 0 의 검증 자료에서만 현장 학습량 8/16/24 장을 비교하고, 시험 자료를 열기 전에 8 장 모델을 주 모델로, 24 장 모델을 민감도 비교로 정하여 그 결정과 가중치 해시를 프로토콜 파일로 고정하였다. 16 장 모델은 시험하지 않았다. 나머지 네 폴드, 시간 분할, 미등록 품종 실험의 모델·임계값·지표도 학습 전에 별도 프로토콜 파일로 고정하였고, 시험 결과를 본 뒤 바꾸지 않았다. OOF 결과는 각 모델의 학습–시험 도어 중복을 제거하지만, 앞선 개발 과정의 선택 영향까지 제거한 중첩 교차검증은 아니다. 모든 학습은 시드 42 한 번으로 수행하였다. 5.6 절의 판정 비율–오류율 곡선은 저장된

점수로 사후에 계산한 탐색 분석이며, 이 곡선으로 임계값을 다시 고르지 않았다.

5. 결과 및 고찰

5.1 실험실에서 현장으로의 전이와 소량 현장 좌표

실험실 영상만으로 학습한 검출기는 폴드 0 의 현장 영상에서 볼트 홀은 모두 찾았지만 모서리 홀을 거의 찾지 못했다(Fig. 2(a)). 시험 그룹 현장 좌표 8 장에서 PCK8 은 볼트 100%, 힌지 측 25%, 래치 측 0%였다. 시험 1,478 장 중 1,315 장이 모서리 홀 누락으로, 나머지도 기하 검사에서 보류되어 시험 도어 74 개를 모두 판정하지 못했다(Table 3). 모서리 홀은 지름 6 mm 로 작고 도어 가장자리에 있어 주변에 지그와 배경이 함께 보이므로, 실험실과 현장의 배경 차이에 민감했던 것으로 보인다. 사람이 주석한 현장 좌표를 그대로 거리 판정에 넣으면 검증 8 장이 모두 맞았다(CAD 잔차 중앙값 1.84 mm, 최대 4.52 mm). 즉 이 표본에서는 정확한 좌표가 주어지면 판정이 가능하였으므로, 검출을 우선 개선할 근거를 얻었다.

현장 영상 8 장을 학습에 추가하자 검증과 시험 모두에서 판정이 회복되었다. 폴드 0 의 시험 도어 74 개와 영상 1,478 장이 모두 정답이었고, 시험 그룹 현장 좌표 48 점 모두 8 화소 이내로 검출되었다(Table 3). 24 장으로 늘려도 시험 결과는 같았고, 검증에서도 16·24 장은 8 장과 같은 세션 결과를 보였다. 나머지 네 폴드에서도 현장 8 장 모델의 시험 그룹 현장 좌표는 폴드마다 48 점 모두 8 화소 이내였다(다섯 폴드 240 점, 검출 오차 중앙값 2.3~2.8 화소). 실험실 전용 모델은 실험실 검증으로, 현장 적응 모델은 현장 검증으로 선택하였으므로 이 차이에는 학습 자료와 모델 선택 자료의 차이가 함께 포함된다. 데이터 기간 이전에 고정된 참조 검출기도 폴드 0 의 시험 도어 74 개를 모두 맞혔다. 이 검출기는 지그 설치 전에 촬영한 한 세션의 현장 영상 16 장(학습 13, 검증 3)으로만 현장을 보았다. 같은 도어 자료로 평가했으므로 독립 표본의 재현은 아니지만, 별도 학습 이력의 검출기에서도 소량의 현장 영상으로 검출이 회복되는 같은 경향을 관찰하였다.

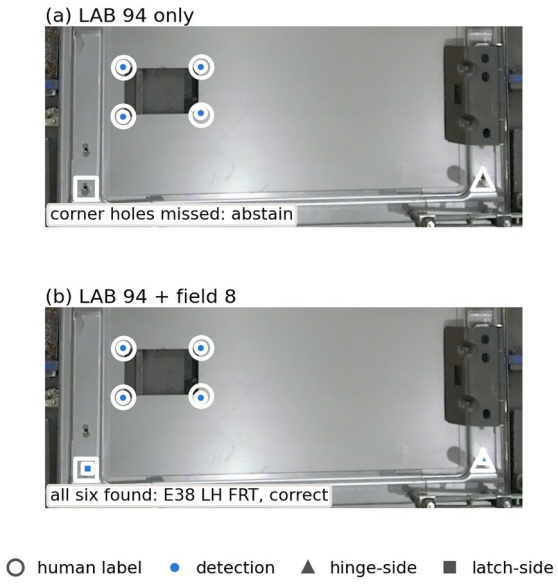


Fig. 2 Detection on a field test image (E38 LH FRT). (a) Detector trained on 94 laboratory images: bolt holes found, both corner holes missed; (b) with eight field images added: all six holes found and the door classified correctly. Hollow white markers: human annotation

Table 3 Effect of field point annotations (fold 0, pixel width). Annotation time is converted from the measured mean of 24.6 s per image (training + selection images); PCK8 H / L: hinge / latch corner holes; frozen ref.: 13 + 3 pre-period field images

Field train	Annot. (min)	Val doors	Test doors (95% CI)	Test images	PCK8 H / L
0 (lab only)	0	0/73	0/74 (0–4.9%)	0/1,478	25% / 0%
8 (main)	3.3 + 3.3	73/73	74/74 (95.1–100%)	1,478/1,478	100% / 100%
16	6.6 + 3.3	73/73	–	–	–
24	9.8 + 3.3	73/73	74/74 (95.1–100%)	1,478/1,478	100% / 100%
Frozen ref.	–	73/73	74/74 (95.1–100%)	1,478/1,478	100% / 100%

5.2 5 겹 교차검증에서의 외관 CNN 과의 비교

다섯 폴드의 시험 결과를 모은 도어 361 개, 영상 7,104 장의 결과를 Table 4 에 나타냈다. 현장 8 장 홀 모델은 361 개 도어를 모두 맞혔고, 영상 7,087 장(99.8%)을 판정하였으며 판정한 영상에서는 오판이 없었다. 보류된 17 장은 모서리 홀 누락과 기하 검사에 의한 것이다. 폴드별로도 시험 도어를 모두 맞혔다(74/74, 73/73, 73/73, 72/72, 69/69). 형상군별로도 모든 도어를 맞혔으나, 가장 적은 E25 LH FRT(9/9)의 Wilson 95% 하한은 70.1%로 희소 형상군의 불확실성은 크다. 재학습 없이

같은 가중치를 쓴 고정 참조 모델도 361 개를 모두 맞혔다.

RGB CNN 은 360 개, RGBE CNN 은 359 개를 맞혔다. 두 CNN 이 공통으로 틀린 도어는 10 월 22 일의 E25 LH FRT 도어 1 개로, 20 장 모두 인접한 E30 LH FRT 로 분류하였고 신뢰도 중앙값은 0.9999998 이었다. 같은 도어에서 홀 방법은 D = 726.3 mm(CAD 724 mm, +0.3%)를 측정하여 20 장을 모두 맞혔다. RGBE CNN 의 다른 오판도 E25 LH FRT 를 E30 LH FRT 로 분류한 경우였다. 이 관측은 학습 자료가 적고 외관이 비슷한 형상군에서 외관 분류기가 높은 신뢰도로 인접 형상군을 출력할 수 있음을 보여 준다.

홀 방법과 RGB CNN 의 세션 정확도 차이는 +0.3%p(bootstrap 95% 구간 0~0.8%p, McNemar p = 1.0)로, 관측 차이는 작고 우월성을 확인하지 못했다. 이 구간은 한 시드와 공유된 학습 자료에서 얻은 것이므로 학습 변동 전체를 포함하지 않는다. 검증 기준 임계값을 적용하면 두 CNN 은 오판 1 개를 남긴 채 361 개 중 11 개(RGB)와 7 개(RGBE)를 보류하였다. 무작위 세션 분할에서 두 방법의 차이는 정확도보다 판정 근거에 있다. 홀 방법은 출력마다 측정 거리와 CAD 값의 차를 근거로 제시하며, 판정 단계에서는 클래스별 분류 가중치 대신 CAD 최근접값을 사용한다.

Table 4 Five-fold out-of-fold identification (361 doors, 7,104 images)

Method	Image accuracy	Image coverage	Doors (95% CI)	Macro-F1
RGB CNN	99.7%	100.0%	360/361 (98.4–99.95%)	0.991
RGBE CNN	99.5%	100.0%	359/361 (98.0–99.9%)	0.982
RGB CNN, threshold	95.3%	95.6%	349/361 (94.3–98.1%)	–
RGBE CNN, threshold	94.8%	95.1%	353/361 (95.7–98.9%)	–
Hole, field 8	99.8%	99.8%	361/361 (98.9–100%)	1.000
Hole, frozen reference	99.7%	99.7%	361/361 (98.9–100%)	1.000

5.3 거리 표현과 판정 여유

같은 검출 좌표(현장 8 장 모델)로 픽셀 폭 방식과 깊이 평면 방식을 비교하였다(Fig. 3, Table 5). 다섯 폴드의 계산 가능한 모든 영상에서 픽셀 폭 방식의 CAD 기준 상대 잔차는 −1.14%에서 +1.11% 사이(절대 최대 14.6 mm)였다. 이는 가장 좁은 판정 여유 ±2.22%의 절반 수준이며, 판정 여유를 벗어난 영상은 없었다. 학습 세션만으로 구한 S 는 폴드별로 1,474~1,475 mm 였고, 깊이로 측정한 도어 평면 거리 중앙값 1,450 mm(5~95 백분위수 1,424~1,472 mm)와 2% 이내로 일치하였다.

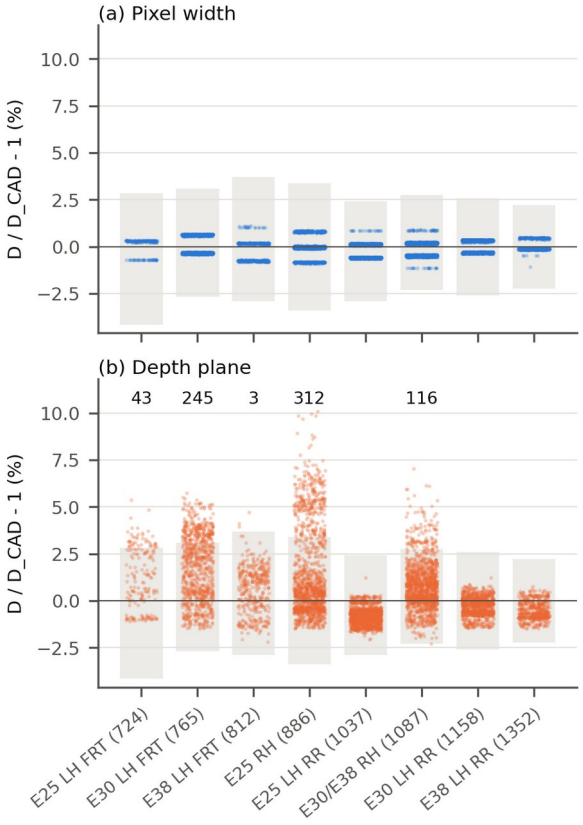


Fig. 3 Relative residual to CAD per class, five-fold out-of-fold predictions of the eight-field-image detectors (361 doors, 7,104 images). (a) Pixel width; (b) depth plane. Gray bars: correct-decision band of each class (Table 1); numbers above: images outside the band

Table 5 Pixel-width versus depth-plane distance with the same detections (five-fold OOF, 7,104 images)

Distance	Doors correct	Doors wrong / abstained	Residual 5th / 50th / 95th (%)	Image residual range (%)
Pixel width	361/361	0 / 0	−0.75 / +0.00 / +0.64	−1.14 to +1.11
Depth plane	332/361	16 / 13	−1.29 / −0.02 / +4.05	−2.29 to +10.08

깊이 평면 방식은 도어 16 개를 오분류하고 13 개를 보류하였다. 오분류 16 개는 모두 실제보다 D 가 큰 이웃 형상군으로 분류되었다(E30 LH FRT→E38 LH FRT 11 개, E30/E38 RH→E30 LH RR 3 개, E25 LH FRT→E30 LH FRT 2 개). 보류 13 개 중 11 개는 E25 RH 에서 측정값이 CAD 값보다 30 mm 이상 크게 나온 경우였다. 영상 단위 잔차는 최대 +10.08%(시간 분할

+10.27%), 도어별 중앙값은 최대 +8.24%였다. 즉 깊이 방식의 잔차는 무작위 잡음보다 일부 도어에서 거리를 크게 재는 한쪽 방향의 치우침으로 나타났다. 폴드 0 에서는 이 경향이 검출기를 바꾸어도(고정 참조 68/74, 현장 24 장 65/74) 남았고, 사람이 찍은 좌표로도 깊이 방식의 CAD 잔차가 최대 31.3 mm 까지 나타났다. 이는 검출보다 깊이 측정과 평면 추정 경로가 주요 제한 요인임을 시사한다. 평면에 포함된 배경, 유효 깊이 화소, 자세의 기여는 분리하지 않았다.

픽셀 폭 방식의 잔차는 도어 내부에서는 거의 변하지 않았다. 한 세션 내 표준편차 중앙값은 0 에 가까웠고, 도어 사이 표준편차는 0.41%였다. 현재 검출점은 히트맵 격자에서 취하므로 원본 영상 기준 약 6.25 화소 간격으로 양자화되며, 이는 D 의 0.5~1.0%에 해당한다. Fig. 3(a)의 계단 모양 분포에는 이 양자화가 영향을 주었을 가능성이 있으며, 부화소 보간의 효과는 후속 검증이 필요하다.

가장 좁은 판정 여유 ±2.22%를 3.4 절의 이상식으로 촬영 거리에 단순 환산하면, 멀어지는 쪽 약 33.5 mm, 가까워지는 쪽 약 32.0 mm 규모이다. 이는 다른 오차를 제외한 일차 민감도이며, 관측된 잔차가 이미 여유의 일부를 사용한다. 따라서 실제 지그 허용 공차는 자세·검출·보정 오차와 통제된 거리 변화 실험을 포함하여 정해야 한다.

5.4 시간 변화에 대한 비교

10 월 3 일 이전 자료로만 학습한 모델을 이후 133 개 도어로 시험하였다(Table 6). 홀 방법은 133 개 도어를 모두 맞혔고 2,617 장 중 2,616 장을 판정하였다. 학습 기간의 현장 좌표에 E30 LH RR 이 없었지만 시험의 E30 LH RR 도어 23 개도 모두 맞혔다. 고정 참조 모델도 133 개를 모두 맞혔다. 학습 기간 세션으로 정한 S 를 그대로 썼으므로 픽셀 폭 방식의 상대 잔차 중앙값은 +0.33%로 약간 이동했으나, 범위는 −0.72%에서 +1.01% 사이로 판정 여유 안에 있었다. 깊이 평면 방식은 108/133 으로 무작위 분할(332/361)보다 낮았다.

RGB 와 RGBE CNN 은 각각 132 개를 맞혔다. 둘 다 5.2 절의 E25 LH FRT 도어를 다시 E30 LH FRT 로 분류하였는데, 이는 같은 실물이 서로 다른 학습 분할에서 반복 오판된 것이며 독립된 두 실패 사례는 아니다. 학습 기간의 검증 영상으로 정한 임계값 운용점에서 RGB CNN 은 시험 영상의 70.8%를 판정하고 도어 25 개를 보류하였다. RGBE CNN 은 영상의 78.1%를 판정하고 도어 20 개를 보류했으며 오판 1 개가 남았다. 보류는 E30 LH FRT 도어 23 개 중 RGB 15 개, RGBE 16 개에 집중되었다. 즉 이 운용점에서는 시기가 바뀐 자료의 신뢰도 분포가 검증 자료와 달라 정상 도어의 보류가 늘었다. 홀 방법은 같은 조건에서 보류 없이 모든 도어를 맞혔다.

Table 6 Temporal split: trained on sessions before October 3, tested on the 133 later doors (2,617 images)

Method	Image accuracy	Image coverage	Doors (95% CI)	Doors wrong / abstained
RGB CNN	99.2%	100.0%	132/133 (95.9–99.9%)	1 / 0
RGBE CNN	99.2%	100.0%	132/133 (95.9–99.9%)	1 / 0
RGB CNN, threshold	70.8%	70.8%	108/133 (73.7–86.9%)	0 / 25
RGBE CNN, threshold	78.1%	78.1%	112/133 (77.1–89.4%)	1 / 20
Hole, field 24 (earlier period)	99.96%	99.96%	133/133 (97.2–100%)	0 / 0
Hole, frozen reference	99.9%	99.9%	133/133 (97.2–100%)	0 / 0
Hole, field 24, depth plane	79.0%	91.3%	108/133 (73.7–86.9%)	18 / 7

5.5 미등록 형상군에 대한 부가 실험

8 개 형상군만 등록된 시스템에 대상 밖 형상군인 E23 LH FRT 도어를 입력하였다(Table 7). E23 LH FRT 의 CAD D 는 458 mm 로, 가장 가까운 등록값(E25 LH FRT, 724 mm)과 266 mm 떨어져 있어 현재 보류 규칙으로 구분하기 쉬운 조건이다. 대상은 4.1 절에서 작업자가 E25 LH FRT 로 잘못 입력하여 제외한 6 세션(120 장)이다. 2026 년 11 월에 수집된 E23 세션은 사람이 정답을 확인하지 않았으므로 사용하지 않았다. 모델은 폴드 0 의 것을 그대로 사용하였다.

홀 방법은 E23 을 등록하지 않은 상태에서 120 장을 모두 CAD 거리 초과로 보류하였다(측정 D 중앙값 454 mm). CAD 값 458 mm 만 추가로 등록하자 재학습 없이 120 장과 6 세션이 모두 E23 으로 판정되었다. 고정 참조 모델도 같은 결과를 보였다. 6/6 의 Wilson 95% 하한은 61.0%이며, 120 장은 6 개 도어에서 나왔으므로 독립된 120 개 표본으로 세지 않는다. 이 결과는 등록 치수와 충분히 떨어지고 같은 홀 배치를 갖는 미등록 형상군 하나에서 거절과 CAD 등록 후 식별을 확인한 것이며, 치수가 가까운 미등록 품종에 대한 성능을 뜻하지 않는다.

RGB CNN 은 6 세션을 모두 E25 LH FRT 로 분류하였다. 이는 작업자가 범한 것과 같은 오류이다. RGBE CNN 은 3 세션을 E25 LH FRT, 3 세션을 E30 LH FRT 로 분류하였다. 검증 기준 임계값을 적용하면 두 CNN 모두 E23 영상을 모두 보류하였고, 같은 운용점에서 폴드 0 의 정상 시험 도어 74 개 중 2 개가 보류되었다. 본 연구의 고정 8 출력 분류기는 E23 을 출력할 수 없으므로 E23 을 식별하려면 E23 영상으로 다시 학습해야 한다.

Table 7 Unregistered class: six E23 LH FRT doors (120 images, D_CAD 458 mm), fold-0 models

Method	E23 not registered	E23 registered (CAD only)	Fold-0 test doors
RGB CNN	6 → E25 LH FRT	Retraining needed	74/74 correct
RGBE CNN	3 → E25, 3 → E30 LH FRT	Retraining needed	73/74 correct
RGB / RGBE, threshold	6/6 rejected	Retraining needed	2/74 abstained
Hole, field 8	6/6 rejected	6/6 E23	74/74 correct
Hole, frozen reference	6/6 rejected	6/6 E23	74/74 correct

5.6 판정 비율과 오류율의 관계(탐색 분석)

임계값 운용점의 선택에 따른 차이를 보기 위해, 저장된 점수로 영상 단위 판정 비율–오류율 곡선을 사후에 계산하였다(Fig. 4). CNN 은 소프트맥스 최대값이 큰 영상부터, 홀 방법은 최근접 CAD 값과의 거리가 작은 영상부터 판정하도록 하고, 홀 방법의 보류 거리는 0~30 mm 범위에서 바꾸었다. 기하 검사를 통과하지 못한 영상은 홀 방법에서 항상 보류된다.

5 겹 OOF(Fig. 4(a))에서 홀 방법은 판정 비율 99.76%까지 판정한 영상에서 오류가 없었다. RGB CNN 은 신뢰도가 1.0 으로 포화된 영상(50.7%)만 판정할 때 오류가 없었고, 그보다 넓게 판정하면 앞의 E25 LH FRT 도어 영상 20 장(신뢰도 0.9999998 이상)이 함께 수락되어 오류율이 0.26~0.45%였다. RGBE CNN 은 오판 영상 일부의 신뢰도가 1.0 이어서 오류가 없는 판정 구간이 없었다. 시간 분할(Fig. 4(b))에서 두 CNN 은 판정 비율을 각각 75.7%와 76.5% 이하로 낮춰야 오류가 없었다. 홀 방법은 99.96%에서 오류가 없었다.

E23(Fig. 4(c))에서 홀 방법은 보류 거리 30 mm 까지 E23 영상을 하나도 수락하지 않았다. 사후에 임계값을 고르면 RGB CNN 도 폴드 0 의 정상 시험 영상을 모두 판정하면서 E23 을 모두 거절하는 구간이 있었다(정상 영상 신뢰도 최소 0.999998, E23 최대 0.99962). RGBE CNN 은 정상 영상 판정 비율 98.4% 이상에서 E23 영상을 수락하기 시작하였다. 따라서 이 자료에서는 CNN 도 적절한 임계값으로 E23 을 걸러낼 수 있었다. 다만 그 구간은 1 에 매우 가까운 좁은 범위였고, 검증으로 정한 임계값은 분할마다 0.99955~1.0 으로 달랐다. 홀 방법의 보류 기준은 CAD 치수 간격에 따라 정한 고정값 30 mm 이다.



Fig. 4 Exploratory risk-coverage analysis from stored scores (image level). (a) Five-fold OOF; (b) temporal split; (c) fold-0 known test images versus the six unregistered E23 doors. Lines: CNN softmax threshold or hole reject distance (0 to 30 mm) swept; markers: pre-specified operating points

5.7 한계

본 연구의 데이터는 한 사업장의 고정 지그와 카메라 한 대에서 수집되었고, 이전 시스템 개발 과정에서 관찰된 기간에 속하므로 분리된 시험 폴드와 시간 분할은 전향적 시험과 구분된다. 생산 로트 정보가 없어 로트 단위

분리는 확인하지 못했다. 정답 검증은 기존 판별 결과와 작업자 입력이 불일치한 세션을 중심으로 이루어졌으므로, 두 결과가 같은 형상군으로 함께 틀린 경우는 걸러지지 않았을 수 있다. 모든 학습은 시드 하나로 수행하였으므로 학습 무작위성에 따른 변동은 보고하지 않았다. E25 LH FRT 와 E23 LH FRT 는 세션 수가 각각 9 개와 6 개로 적다. 현장 좌표의 필요량은 이 현장에서 확인한 것이며, 다른 지그·조명·카메라에서 필요한 주석량은 별도로 검증해야 한다. 지그 위치 공차는 민감도 환산만 제시하였고 거리·자세를 통제한 실험은 하지 않았다. 픽셀 폭 방식은 촬영 거리가 일정하다는 전제에 의존하므로, 거리가 변하는 셀에서는 볼트 홀 피치 등을 이용한 영상별 축척 추정이 필요하다. 판정이 거리 D 하나에 의존하므로 같거나 가까운 D 를 갖는 품종이 추가되면 다른 랜드마크가 필요하다. CNN 비교는 고정 8 출력 분류기와 소프트맥스 임계값 기준선에 한정되며, 신뢰도 보정이나 개방 집합 CNN 은 비교하지 않았다.

6. 결 론

굴착기 도어 8 개 형상군을 상단 모서리 홀 사이 거리와 CAD 값의 대조로 식별하는 방법을, 한 사업장의 고정 지그에서 수집한 실제 생산 도어 361 개의 영상으로 후향적으로 평가하였다. 실험실 영상만으로 학습한 홀 검출기는 현장에서 모서리 홀을 찾지 못해 폴드 0 의 시험 도어 74 개를 모두 보류하였다. 같은 현장에서 폴드마다 학습용 8 장과 모델 선택용 8 장의 수동 좌표를 추가한 모델은 5 겹 교차검증에서 361 개 도어를 모두 맞혔고, 이전 기간의 현장 좌표만 쓴 모델도 이후 133 개 도어를 모두 맞혔다. 학습용 8 장의 주석 시간은 실측 평균으로 환산하여 약 3.3 분이며, 새 현장에 필요한 주석량은 별도 검증이 필요하다.

같은 검출점에서도 거리 표현에 따라 잔차와 실패 양상이 달랐다. 픽셀 폭 기반 거리의 CAD 기준 상대 잔차는 영상 단위 최대 1.14%로 가장 좁은 판정 여유 ±2.22%의 절반 수준이었다. 깊이 평면 기반 거리는 영상 단위 최대 +10.08%까지 큰 쪽으로 치우쳐 도어 16 개를 오분류하고 13 개를 보류하였다. 따라서 이 고정 지그 환경에서는 픽셀 폭 방식이 적합하였다. 판정 여유를 촬영 거리로 단순 환산하면 약 33 mm 규모이나, 실제 지그 공차는 다른 오차와 통제 실험을 포함하여 정해야 한다.

무작위 분할에서 외관 CNN 의 정확도는 홀 방법과 비슷하였고 우월성은 확인되지 않았다. 차이는 판정 근거와 일부 조건에서 나타났다. CNN 은 세션이 적은 E25 LH FRT 도어 1 개를 두 분할에서 높은 신뢰도로 인접 형상군에 분류하였고, 검증 기준 임계값 운용점에서는 시간 분할의 정상 도어 133 개 중 20~25 개를 보류하였다. 홀 방법은 같은 조건에서 보류 없이 모든 도어를 맞혔으며, 등록 치수와 266 mm 떨어진 미등록 형상군 E23 의 도어 6 개를 거절하고 CAD 값 등록만으로 식별하였다. 이러한 결과는 판정 근거의 추적과 품종 추가가 필요한 고정 지그 공정에서 홀 랜드마크와 CAD 치수 대조가 외관 분류기의 실용적인 대안 또는 보완이 될 수 있음을 보여 준다.

후 기

이 논문은 【부처명 확인】·한국산업기술평가관리원(KEIT)의 【사업명 확인】 지원을 받아 수행된 연구임(과제번호 25453759, 굴착기 혼류 생산을 위한 로봇용접 및 AI 기반 영상 PAUT 복합 검사 시스템 개발).

References

[1] He, K., Zhang, X., Ren, S., Sun, J., 2016, Deep Residual Learning for Image Recognition, Proc. IEEE Conf. Comput. Vis. Pattern Recognit. 770-778.

[2] Prünte, P., Schoepflin, D., Schüppstuhl, T., 2023, A Comparative Study of Visual Identification Methods for Highly Similar Engine Tubes in Aircraft Maintenance, Repair and Overhaul, Sensors 23:15 6779.

[3] Behnen, H., Boada-Gardenyes, G., Schmitt, R. H., Teschner, M., Pönitz, W., Weiß, K., 2026, Sheet Metal Localization Using Deep Learning and Synthetic Data, J. Intell. Manuf. 37 399-415.

[4] Lin, S., Xiao, S., Lin, R., Wu, J., Luo, W., 2026, Multi-feature Dimension Measurement Method for Sheet Metal Parts Based on PRT Files and Machine Vision, Measurement 258 119276.

[5] Scheirer, W. J., de Rezende Rocha, A., Sapkota, A., Boult, T. E., 2013, Toward Open Set Recognition, IEEE Trans. Pattern Anal. Mach. Intell. 35:7 1757-1772.

[6] Hendrycks, D., Gimpel, K., 2017, A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks, Proc. Int. Conf. Learn. Represent.

[7] Lin, T.-Y., Dollár, P., Girshick, R., He, K., Hariharan, B., Belongie, S., 2017, Feature Pyramid Networks for Object Detection, Proc. IEEE Conf. Comput. Vis. Pattern Recognit. 2117-2125.

[8] Xiao, B., Wu, H., Wei, Y., 2018, Simple Baselines for Human Pose Estimation and Tracking, Proc. Eur. Conf. Comput. Vis. 466-481.

[9] Geifman, Y., El-Yaniv, R., 2019, SelectiveNet: A Deep Neural Network with an Integrated Reject Option, Proc. Int. Conf. Mach. Learn. 2151-2159.

[10] Bendale, A., Boult, T. E., 2016, Towards Open Set Deep Networks, Proc. IEEE Conf. Comput. Vis. Pattern Recognit. 1563-1572.