고정 지그 환경에서 홀 랜드마크와 CAD 치수 대조를 이용한 굴착기 도어 형상군 식별

Identification of Excavator Door Shape Classes Using Hole Landmarks and CAD Dimension Matching in a Fixed Jig

ABSTRACT

Excavator door shape classes look alike but differ in the CAD distance D between two corner holes. We separate a class-shared hole detector from a CAD list: the detected corner holes give D from a pixel width, and a door takes the nearest registered value or is rejected beyond 30 mm. In a retrospective study of 361 production doors in a fixed jig, detectors adapted with 8–24 field images identified every door in five-fold cross-validation and all 133 later doors; appearance CNNs identified 360 and 359. Residuals used at most half of the decision margins, and sub-pixel peaks reduced their RMS from 0.42% to 0.24%. With each class removed from all training (three seeds), all 74 held-out doors were rejected while unregistered and identified once only the CAD value was registered; at a 95%-acceptance threshold, a CNN with a feature-distance score rejected 69–74 but also 6–9% of registered doors.

Key Words: Excavator door, Part identification, Hole landmark, CAD dimension, Decision margin, Unregistered class

1. 서 론

다품종 혼류 생산에서는 작업 대상 부품의 종류를 먼저 식별해야 용접 조건과 로봇 작업 경로를 선택할 수 있다. 굴착기 측면 도어는 기종(E25·E30·E38)과 위치(좌·우, 앞·뒤)에 따라 여러 형상군으로 나뉘지만, 같은 공정의 박판 프레스 부품이어서 외관이 서로 비슷하다(Fig. 1). 대상 공정에서는 작업자가 형상군을 선택하는데, 본 연구의 수집 기간에 기록된 374 세션 가운데 작업자 입력이 실제 형상군과 다른 것으로 확인된 세션이 11 개(2.9%)였다. 이 중 6 개는 선택 목록에 없는 형상군의 도어였고, 목록에 있는 형상군 사이의 오입력은 5 개(1.3%)였다. 이러한 부품의 영상 식별에는 외관 기반 합성곱 신경망(CNN)[1]이 널리 쓰이며, 외관이 매우 유사한 부품에서는 표현의 선택이 성능을 좌우한다[2]. 외관 분류기는 형상군마다 학습 영상이 필요하고, 출력이 고정되어 있어 학습하지 않은 형상군의 이름을 낼 수 없으며 그 입력을 기존 형상군 중 하나로 출력할 수 있다[3,4]. 이러한 입력을 걸러내기 위해 소프트맥스 최대값[4], 최대 로짓[5], 에너지[6], 특징 공간의 마할라노비스 거리[7]와 같은 점수가 제안되었다.

대상 도어의 형상군 차이는 설계 치수로 정의된다. 세로 프레임 상단의 두 모서리 홀 사이 거리 D 가 형상군마다 다르고(Table 1), 모든 형상군이 같은 종류의 홀 배치를 공유한다. 본 연구는 이 구조를 이용하여 영상에서 학습하는 검출 가중치와 형상군별 판정 목록을 분리한다. 검출기는 모든 형상군에 공통인 홀 6 점만 출력하고, 형상군은 측정 거리를 CAD 치수 목록과 대조하여 정하며, 어느 등록값과도 맞지 않으면 보류한다. 이는 기하 모델을 영상 특징과 대조하는 모델 기반 인식[8]과, 클래스를 속성으로 기술하여 학습 영상이 없는 클래스를 인식하는 속성 기반 분류[9]의 생각을 생산 부품 식별에 적용한 것이며, 여기서는 CAD 치수가 속성의 역할을 한다. 판금 부품에서는 학습 기반 코너 검출로 위치를 추정한 연구[10]와 CAD 정보로 홀·슬롯 치수를 측정한 연구[11]가 있으나, 이들은 위치 추정과 치수 검사를 다루며 측정 치수를 형상군 식별의 판정 근거로 쓰지는 않았다. 홀 검출에는 특징 피라미드[12]와 히트맵 회귀[13]의 일반적인 구조를 사용하며, 구조 자체의 새로움은 주장하지 않는다.

이 분리 구조의 두 가지 성질을 한 사업장의 고정 지그에서 수집한 실제 생산 도어 361 개로 후향적으로 평가하였다. 첫째, 식별이 치수 측정이 되므로 판정의 근거를 물리 단위의 판정 여유로 나타낼 수 있다. 픽셀 폭과 깊이 평면의 두 거리 표현을 판정 여유와 비교하고, 부화소 보간의 효과를 확인하였다. 둘째, 판정 목록이 검출 가중치 밖에 있으므로 형상군의 등록이 목록의 변경으로 이루어진다. 8 개 형상군을 하나씩 모든 학습에서 빼고, 그 형상군의 도어가 미등록일 때 보류되는지와 CAD 값만 등록하면 식별되는지를 확인하였으며, 미등록 도어의 보류를 외관 CNN 의 네 가지 점수와 비교하였다.

2. 제안 방법

2.1 대상 형상군과 분리 구조

대상은 굴착기 측면 도어 8 개 형상군이다(Fig. 1, Table 1). E30 과 E38 의 우측 도어는 같은 형상이므로 한 형상군으로 묶었다. 기준 치수 D 는 힌지 측과 래치 측 상단 모서리 홀(Ø6) 중심 사이의 CAD 거리이며, 8 개 형상군 모두 값이 다르다. 제안 방법은 모든 형상군에 공통인 홀 6 점의 검출기와 형상군별 CAD 거리 목록으로 이루어진다(Fig. 2). 검출기는 형상군 라벨을 출력하지 않으며, 형상군의 추가와 제거는 목록의 변경이므로 검출기의 재학습을 요구하지 않는다. 다만 새 형상군은 같은 홀 배치를 가져야 하고, 그 CAD 값과 기존 값의 간격이 측정 잔차에 비해 충분해야 한다. 형상군 라벨은 축척 보정(2.3 절)과 현장 좌표 표본의 선택(3.2 절)에도 쓰이므로, 여기서 분리는 검출 가중치와 판정 목록 사이의 운영상 분리를 뜻한다.

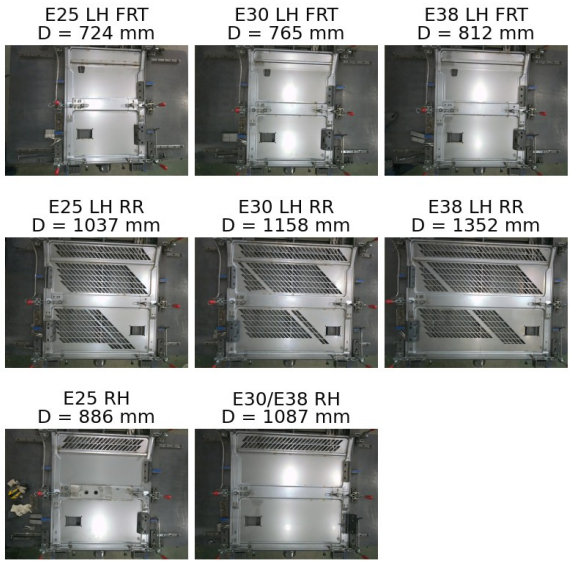


Fig. 1 Field images of the eight door shape classes in the jig (same crop for all classes) with the CAD distance D. Rows: LH front, LH rear, and RH doors

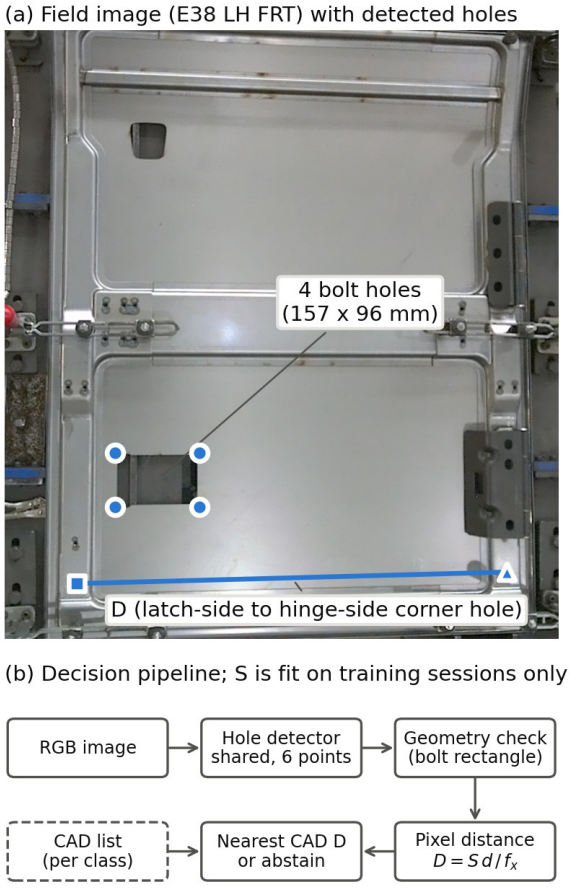


Fig. 2 (a) Field image of an E38 LH FRT door with the six detected holes and the measured distance D; (b) decision pipeline. The detector is shared by all classes; the decision list holds the CAD values. The scale S is fit on training sessions only

Table 1 Door shape classes, CAD distance D, field data, and decision margin (relative to D)

Class	D (mm)	Doors	Images	Margin (%)
E25 LH FRT	724	9	180	−4.14 / +2.83
E30 LH FRT	765	44	867	−2.68 / +3.07
E38 LH FRT	812	21	410	−2.89 / +3.69
E25 RH	886	68	1,343	−3.39 / +3.39
E25 LH RR	1,037	70	1,388	−2.89 / +2.41
E30/E38 RH	1,087	70	1,398	−2.30 / +2.76
E30 LH RR	1,158	50	984	−2.59 / +2.59
E38 LH RR	1,352	29	534	−2.22 / +2.22
Total	–	361	7,104	–

2.2 홀 검출과 기하 검사

검출기는 ImageNet 으로 초기화한 ResNet18[1] 인코더와 특징 피라미드형 복원부[12,13]로 구성하였다. 입력 RGB 영상을 종횡비를 유지하여 1280×768 로 변환하고 1/4 해상도의 히트맵 세 채널을 출력한다. 첫 채널은 래치 측 볼트 홀 4 개를, 나머지 두 채널은 힌지

측과 래치 측 모서리 홀을 표현한다. 정답 히트맵은 표준편차 2의 가우시안이고, 손실은 정답 응답에 비례하는 가중치(1+20H)를 둔 평균 제곱 오차이다. 증강은 임의 회전(±180°), 크기(0.8~1.15), 좌우 반전, 밝기·흐림 변화를 사용하였고, AdamW(학습률 1×10^{-4}, 코사인 감쇠), 배치 4, 80 epoch로 학습하였다. 응답 0.15 이상의 극대점을 볼트 채널에서 최대 4개, 모서리 채널에서 1개씩 검출점으로 취한다. 주 결과는 히트맵 격자의 정수 극대점을 쓰며, 이는 원본 영상에서 6.25화소 간격에 해당한다. 극대점과 이웃 두 값의 2차 보간으로 부화소 위치를 구하는 방식은 4.3절에서 비교한다.

네 볼트 홀은 CAD상 157×96 mm 직사각형을 이룬다. 검출된 네 점의 장변과 단변 방향 축척의 차이가 18%를 넘으면 그 배열을 쓰지 않고, 통과한 배열을 기준으로 래치 측 모서리 홀이 설계상 위치 범위에 있는지와 두 모서리 홀이 볼트 배열의 서로 반대편에 있는지 검사한다. 이 기하 검사를 통과하지 못하거나 모서리 홀이 검출되지 않으면 그 영상의 판정을 보류한다. 거리 D의 계산에는 두 모서리 홀만 쓰인다. 볼트 홀 4점은 치수를 아는 기준 배열로서 모서리 홀의 오검출을 걸러내는 이 기하 검사와 깊이 평면 방식의 평면 추정(2.3절)에 쓰이며, 본 자료에서는 기하 검사의 기여가 작았다(4.3절).

2.3 거리 추정, 판정과 판정 여유

두 모서리 홀의 영상 좌표 p_h, p_l과 수평 초점거리 f_x로 거리를 계산한다(픽셀 폭 방식).

$$D = S\cdot \| p_h - p_l \| / f_x \tag{1}$$

도어가 광축에 수직인 평면에 놓이면 S는 카메라–도어 거리에 해당하며, 고정 지그에서는 상수로 둘 수 있다. S는 학습 세션에서 CAD 거리와 정규화 픽셀 거리의 비를 세션별 중앙값으로 구한 뒤 그 중앙값으로 정하였다. 비교를 위한 깊이 평면 방식은 검출점들의 볼록 껍질 내부 깊이 화소에 평면을 맞추고(잔차 10 mm 이내의 점으로 재추정), 두 모서리 홀의 시선을 평면과 교차시켜 얻은 3차원 거리에 학습 세션에서 구한 상수를 곱한다.

판정은 등록된 CAD 값 D_c 가운데 측정값과 가장 가까운 형상군을 고른다.

$$\hat{c} = \arg\min_c |D - D_c| \tag{2}$$

최소 차 $|D - D_{\hat{c}}|$가 τ = 30 mm를 넘으면 보류한다(정확히 30 mm이면 수락하고, 차가 같으면 목록에서 앞선 형상군을 고른다). 30 mm는 과거 개발에서 정해본 평가 전에 고정한 값이다. 도어 한 개(세션)의 판정은 판정된 영상들의 최빈값이며, 동률이거나 모두 보류이면 도어도 보류한다. 이 규칙은 측정값이 모든 등록값에서 30 mm 넘게 떨어졌는지를 검사하는 것이므로, 미등록 형상군의 측정값이 어느 등록값의 30 mm 안에 들어오면 그 형상군으로 판정될 수 있다.

형상군 c가 올바르게 판정되는 측정 거리의 범위는 인접 형상군과의 중간값과 ±30 mm 경계 중 안쪽이다. 이를 CAD 값에 대한 상대 잔차로 나타낸 것이 Table 1의 판정 여유 $[l_c, u_c]$이다. 절대 간격이 가장 작은 쌍은 E25 LH FRT–E30 LH FRT(41 mm)이고, 상대 여유는 E38 LH RR(±2.22%)이 가장 좁다. 도어 단위로는 측정 가능한 영상들의 상대 잔차 중앙값 $r = \mathrm{median}(D/D_c - 1)$이 판정 여유를 얼마나 쓰는지를 여유 사용률 U로 나타낸다.

$$U = r / u_c \ (r \geq 0),\quad U = r / l_c \ (r < 0) \tag{3}$$

$U < 1$은 중앙 측정값이 판정 여유 안에 있음을 뜻한다. U는 정답 CAD 값을 쓰는 진단 통계이며, 도어 판정은 영상들의 최빈값으로 정해지므로 U와 도어의 성공·실패가 일대일로 대응하지는 않는다.

3. 실험 방법

3.1 현장 데이터

데이터는 2026년 8월 27일부터 10월 29일까지 도어 용접 공정의 고정 지그 상부에 설치한 스테레오 카메라 1대(ZED X Mini, 1920×1200, 좌안 RGB와 NEURAL 모드의 정합 깊이)와 임베디드 장치(Jetson Orin NX)로 수집하였다. 작업자가 도어를 지그에 거치하고 형상군을 선택하면 2초 간격으로 영상이 저장되며, 한 세션은 생산 중인 도어 1개에 해당한다. 기간 중 기록된 374세션에서 빈 지그와 설치 조정 중의 촬영 2세션, 작업자 입력이 실제 형상군과 다른 11세션을 제외한 361세션(서로 다른 실물 도어 361개)을 사용하였다. 361세션의 원 수집 36,142쌍 가운데, 운용 데이터베이스가 세션마다 시간축에서 균등 간격으로 약 20장씩 복사해 둔 7,376쌍에서 세션당 최대 20장을 균등 추출하여 7,104쌍을 고정하였다. 이 표본 규칙은 영상의 내용이나 모델 출력을 쓰지 않는다.

정답은 작업자가 선택한 형상군이다. 수집된 세션에는 제안 방법과 같은 원리의 운용 판별기(홀 검출 모델과 CAD 거리 대조. 처음의 검출 모델이 3.2절의 고정 참조 모델이며, 9월 23~24일에 검출 모델을 교체하고 거리 계산을 깊이 평면에서 픽셀 폭으로 바꾸었다)를 적용해

두었다. 저자 1 인이 유효한 372 세션의 영상을 모두 육안으로 확인하였다. 이 판별기의 세션 판정이 작업자 입력과 다른 세션은 11 개였고 11 개 모두 입력 오류였으며, 나머지 361 세션에서는 판별기의 판정과 작업자 입력, 육안 확인이 일치하였다. 입력 오류 11 세션 중 6 세션은 선택 목록에 없는 E23 LH FRT 도어였으며, 4.4 절의 미등록 형상군 실험에만 사용하였다. 육안 확인은 영상으로 한 것이며, 실물 측정이나 독립된 제 2 확인자의 검증은 아니다.

3.2 분할, 현장 좌표와 비교 조건

세션을 형상군별로 층화하여 다섯 그룹으로 나누었고, 같은 도어의 영상은 한 그룹에만 속한다. 5 겹 교차검증에서는 그룹 k 를 시험, 그룹 k+1(mod 5)을 검증, 나머지를 학습에 사용하여, 모든 도어가 그 도어를 학습하지 않은 모델로 한 번씩 판정된다. 시간 분할에서는 10 월 3 일 이전 228 세션을 학습(193)과 검증(35)에, 이후 133 세션을 시험에 사용하였다. 시간 분할의 시험 도어는 361 개의 일부이다.

홀 검출기의 좌표 주석은 실험실 영상 118 장(학습 94, 검증 24)과 현장 영상 40 장이다. 현장 좌표는 모델 출력과 무관하게 형상군×그룹마다 한 세션의 가운데 영상을 골라 저자 1 인이 주석하였고, 240 점에 16 분 23 초(장당 24.6 초)가 걸렸다. 각 폴드에서 학습 그룹의 24 장 중 형상군당 1 장씩 8 장을 실험실 94 장에 더해 학습하고, 검증 그룹 8 장으로 체크포인트를 선택하였으며, 시험 그룹 8 장은 검출 정확도(사람 주석과 원본 해상도 8 화소 이내로 일치하는 비율, PCK8)의 평가에만 썼다. 시간 분할에서는 학습 기간의 현장 좌표 24 장을 학습에, 검증 기간의 3 장을 선택에 사용하였다. 비교를 위해 현장 좌표 없이 학습한 실험실 전용 모델과, 데이터 기간 전인 8 월 26 일에 학습을 마친 고정 참조 모델을 함께 평가하였다. 고정 참조 모델은 실험실 94 장과 지그 설치 전 시험 촬영 세션 1 개의 현장 13 장으로 학습하였고 본 데이터의 어떤 세션도 학습하지 않았으므로, 모든 분할에서 같은 가중치로 평가하였다. 모든 홀 조건에서 축척 S 는 각 분할의 학습 세션으로만 정하였다.

외관 비교군은 ImageNet 으로 초기화한 ResNet18 분류기이며 각 분할의 학습 세션 형상군 라벨로 학습하였다(Table 2). 입력은 448×448 RGB 와, RGB 에 Canny 엣지를 더한 4 채널(RGBE)이다. Adam(학습률 3×10^{-4})으로 최대 40 epoch 학습하고 검증 세션의 균형 정확도로 모델을 선택하였다.

Table 2 Compared methods and the supervision each uses (per fold)

Method	Field class labels	Field points (train / select)	Lab points (train / val)
RGB / RGBE CNN	Training, selection	–	–
Hole, lab only	Scale S	0 / 0	94 / 24
Hole, field adapted	Scale S, sampling	8 / 8	94 / 24
Hole, temporal	Scale S, sampling	24 / 3	94 / 24
Hole, frozen ref.	Scale S	13 / 3 (pre-period)	94 / 24

3.3 미등록 형상군 실험과 CNN 의 보류 점수

8 개 형상군을 하나씩 등록 목록에서 빼고, 그 형상군의 시험 도어를 미등록 입력으로, 나머지 7 개 형상군의 시험 도어를 등록 입력으로 사용하였다. 두 방법이 뺀 형상군을 학습에서 보았는지에 따라 두 조건을 두었다.

공통 학습 조건. 두 방법 모두 뺀 형상군을 학습한 상태에서 목록에서만 뺀다. 홀 방법은 검출기와 S 를 그대로 두고 CAD 값만 뺐고, CNN 은 8 출력 분류기에서 해당 출력을 가리고 나머지 출력으로 판정하였다. 재학습은 없으며 다섯 폴드에서 평가하였다.

공통 미학습 조건. 두 방법 모두 뺀 형상군을 학습에서 보지 않는다. 홀 검출기는 해당 형상군의 영상을 실험실 학습 영상(형상군당 11~12 장)과 현장 영상에서 모두 빼고 다시 학습하였고(실험실 82~83 장과 현장 7 장으로 학습, 현장 7 장으로 선택), S 도 해당 형상군을 뺀 학습 세션으로 정하였다. CNN 은 해당 형상군을 뺀 학습·검증 세션으로 7 출력 분류기를 새로 학습하였다. 폴드 0 에서 평가하였고, 학습의 임의성을 보기 위해 평가 전에 정해 둔 시드 목록(42, 123, 456)으로 세 번 반복하였다(홀 검출기 24 개, CNN 48 개). 이 조건의 홀 검출기에는 검출기와 S 를 그대로 두고 뺀 형상군의 CAD 값만 다시 등록하여 그 형상군의 도어가 식별되는지도 평가하였다(CAD 등록).

CNN 의 보류에는 네 가지 점수를 사용하였다. 소프트맥스 최대값[4], 최대 로짓[5], 에너지(로짓의 log-sum-exp)[6], 그리고 512 차원 전역 평균 풀링 특징에서 학습 영상으로 구한 형상군별 평균과 공통 공분산에 대한 마할라노비스 거리의 최솟값[7]이다. 소프트맥스 최대값은 단정밀도 계산에서 1.0 으로 포화되어 동점이 생기므로, 같은 순서를 주는 로그 오즈 $z_{max} - \log \Sigma_{j \neq max}$

exp z_j를 배정밀도로 계산하였다. 임계값은 모델과 점수마다 검증 영상의 최소 95%를 수락하는 값으로 정하였다. 홀 방법의 점수는 가장 가까운 등록 CAD 값과의 거리의 음수이며(기하 검사를 통과하지 못한 영상은 최저점), 보류 기준은 30 mm 로 고정되어 있다.

각 조건에서 미등록 도어의 보류, 등록 도어의 판정, 임계값과 무관한 영상 단위 AUROC 를 보고한다. 등록 도어 판정 518 건(74×7)과 2,527 건(361×7)은 같은 도어가 7 개 실행에 반복해서 들어간 판정 건수이다. AUROC 는 실행별 값의 평균과 최솟값으로 나타냈다. 학습에 전혀 없던 대상 밖 형상군으로는 E23 LH FRT 도어 6 개(120 장, CAD D 458 mm)를 8 개 형상군이 등록된 폴드 0 모델에 입력하였다.

3.4 평가 지표와 절차

모든 정확도는 보류를 분모에 포함한 전체 입력 기준이며, 영상 단위와 도어 단위 결과를 함께 보고한다. 도어 정확도에는 Wilson 95% 신뢰구간을 붙였다. 거리의 정답은 실물 실측값이 아니라 각 형상군의 CAD 값이므로, 거리 오차는 CAD 기준 상대 잔차로 나타냈다.

본 연구는 후향적 평가이다. 실험실 전용 검출기의 첫 시험이 실패한 것을 확인한 뒤 현장 적응을 설계하였고, 폴드 0 의 검증 자료에서 현장 학습량(8·16·24 장)을 비교하여 시험 자료를 열기 전에 8 장 모델을 주 모델로 정하였다. 이후의 분석은 모델·임계값·지표를 실행 전에 프로토콜 파일로 고정하고 결과를 본 뒤 바꾸지 않았다. 다만 CNN 의 네 가지 점수, CAD 등록, 부화소 보간, 시드 반복은 첫 결과(단정밀도 소프트맥스 점수, 시드 하나)를 검토한 뒤 추가로 설계한 분석이다. 미학습 조건을 제외한 학습은 시드 42 한 번으로 수행하였다. 교차검증 결과는 각 모델의 학습–시험 도어 중복을 제거하지만, 개발 과정의 선택 영향까지 제거한 중첩 교차검증은 아니다.

4. 결과 및 고찰

4.1 소량의 현장 좌표에 의한 검출 회복

실험실 영상만으로 학습한 검출기는 폴드 0 의 현장 영상에서 볼트 홀은 모두 찾았지만 모서리 홀을 거의 찾지 못해(PCK8 힌지 측 25%, 래치 측 0%) 시험 도어 74 개를 하나도 판정하지 못했다. 모서리 홀은 지름 6 mm 로 작고 도어 가장자리에 있어 실험실과 현장의 배경 차이에 민감했던 것으로 보인다. 현장 영상 8 장을 학습에 더하자 폴드 0 의 시험 도어 74 개와 영상 1,478 장이 모두 정답이었고, 24 장으로 늘려도 결과는 같았다. 다섯 폴드의 시험 그룹 현장 좌표 240 점은 모두 8 화소 이내로 검출되었다(오차 중앙값 2.3~2.8 화소). 실측 평균으로 환산한 주석 시간은 학습용 8 장이 약 3.3 분, 선택용 8 장을 합해 약 6.6 분이다. 실험실 전용 모델은 실험실 검증으로, 현장 적응 모델은 현장 검증으로 선택하였으므로 이 차이에는 모델 선택 자료의 차이가 함께 포함된다. 지그 설치 전 한 세션의 현장 영상만 본 고정 참조 모델도 폴드 0 의 74 개를 모두 맞혔다.

4.2 식별 성능

5 겹 교차검증의 도어 361 개와 시간 분할의 도어 133 개에 대한 결과를 Table 3 에 나타냈다. 현장 8 장 홀 모델은 361 개 도어를 모두 맞혔고, 영상 7,104 장 중 7,087 장(99.8%)을 판정하여 오판이 없었다. 보류된 17 장은 모서리 홀 누락(14 장)과 기하 검사(3 장)에 의한 것이다. 도어가 가장 적은 E25 LH FRT(9/9)의 Wilson 95% 하한은 70.1%로, 희소 형상군의 불확실성은 크다. 이전 기간의 자료로만 학습한 시간 분할 모델(현장 좌표 24 장 학습, 3 장 선택)도 이후 도어 133 개를 모두 맞혔고(영상 2,616/2,617), 학습 기간의 현장 좌표에 없던 E30 LH RR 도어 23 개도 모두 맞혔다. 재학습 없이 같은 가중치를 쓴 고정 참조 모델도 두 평가에서 모든 도어를 맞혔다.

RGB CNN 은 360 개, RGBE CNN 은 359 개를 맞혔다. 두 CNN 이 공통으로 틀린 도어는 10 월 22 일의 E25 LH FRT 도어 1 개로, 20 장 모두 인접한 E30 LH FRT 로 분류하였다. 같은 도어에서 홀 방법은 D = 726.3 mm(CAD 724 mm)를 측정하였다. RGBE CNN 의 다른 오판도 같은 날의 E25 LH FRT 도어였고, 이 도어의 측정 D 도 726.3 mm 였다. 시간 분할에서도 두 CNN 은 앞의 도어를 다시 틀려 132 개를 맞혔다. 홀 방법과 RGB CNN 의 도어 정확도 차이는 +0.3%p(bootstrap 95% 구간 0~0.8%p, McNemar p = 1.0)로, 등록된 형상군만 입력되는 조건의 정확도에서는 우월성을 확인하지 못했다. 두 방법의 차이는 판정 근거와 보류의 운용에 있다. 홀 방법은 출력마다 측정 거리와 CAD 값의 차를 제시하며, 30 mm 보류 규칙을 적용한 상태에서 모든 도어를 판정하였다. CNN 에 보류 임계값을 적용하면 5 겹에서 7~12 개, 시간 분할에서 5~28 개 도어가 보류되었다(4.4 절).

세션의 첫 1장만으로 판정해도 홀 방법은 361개 도어를 모두 맞혀 20장의 최빈값과 결과가 같았고, 두 CNN도 20장일 때와 같은 360개와 359개를 맞혔다. 학습용 PC(RTX 5090)에서 영상 1장의 처리 시간은 영상 복호화(평균 30.6 ms)를 제외하고 홀 방법(검출·기하 검사·판정)이 평균 14.9 ms, CNN의 전방 계산이 8.6 ms였다. 현장의 임베디드 장치에서는 측정하지 않았다.

Table 3 Identification in five-fold cross-validation (361 doors, 7,104 images) and in the temporal split (133 later doors). Field-adapted hole detectors use 8 field training images per fold (24 in the temporal split)

Method	Image accuracy / coverage (five-fold)	Doors, five-fold (95% CI)	Doors, temporal (95% CI)
RGB CNN	99.7% / 100%	360/361 (98.4–99.95%)	132/133 (95.9–99.9%)
RGBE CNN	99.5% / 100%	359/361 (98.0–99.8%)	132/133 (95.9–99.9%)
Hole, field adapted	99.8% / 99.8%	361/361 (98.9–100%)	133/133 (97.2–100%)
Hole, frozen ref.	99.7% / 99.7%	361/361 (98.9–100%)	133/133 (97.2–100%)

4.3 거리 표현과 판정 여유

같은 검출 좌표로 픽셀 폭 방식과 깊이 평면 방식을 비교하였다(Fig. 3, Table 4). 다섯 폴드의 측정 가능한 모든 시험 영상에서 픽셀 폭 방식의 상대 잔차는 −1.14%에서 +1.11% 사이(절대 최대 14.6 mm)였고, 판정 여유를 벗어난 영상은 없었다. U는 최대 0.50으로, 가장 불리한 도어도 판정 여유의 절반만 사용하였다. 학습 세션만으로 구한 S는 폴드별로 1,474~1,475 mm였고, 깊이로 측정한 도어 평면 거리의 중앙값 1,450 mm와 2% 이내로 일치하였다. 시간 분할에서도 잔차는 −0.72%에서 +1.01% 사이였고 U는 최대 0.36이었다.

깊이 평면 방식은 도어 16개를 오분류하고 13개를 보류하였다. 오분류는 모두 D가 더 큰 이웃 형상군이었고, 영상 단위 잔차는 최대 +10.08%, U는 최대 2.43이었다. 즉 깊이 방식의 잔차는 무작위 잡음보다 일부 도어에서 거리를 크게 재는 한쪽 방향의 치우침으로 나타났다. 폴드 0에서는 이 경향이 검출기를 바꾸어도 남았고 사람이 찍은 좌표로도 CAD 잔차가 최대 31.3 mm였으므로, 검출보다 깊이 측정과 평면 추정이 주요 제한 요인으로 보인다. 학습 세션을 같은 규칙으로 다시 판정해도 픽셀 폭 방식은 실패가 없었고 깊이 방식은 7.8%가 실패하여, 두 표현의 차이는 학습 자료에서도 관찰되었다.

픽셀 폭 방식의 잔차는 한 도어 안에서는 거의 변하지 않고 도어 사이에서 계단 모양으로 나타났는데(Fig. 3(a)), 이는 정수 극대점이 6.25화소 간격으로 양자화되기 때문이다. 2차 보간으로 부화소 위치를 구하면 시험 그룹 현장 좌표의 검출 오차 중앙값이 2.58화소에서 0.77화소로 줄었다. 상대 잔차의 RMS는 0.42%에서 0.24%로, 범위는 −0.87%~+0.66%(최대 11.8 mm)로, U의 최댓값은 0.39로 줄었고, 도어 판정은 361개 모두 정답으로 같았다(Table 4). 부화소 보간은 첫 결과를 본 뒤 추가한 비교이므로 다른 절의 결과는 정수 극대점 기준으로 유지하였다.

기하 검사를 꺼도 도어 판정은 5겹과 시간 분할 모두에서 달라지지 않았다. 영상 단위로는 기하 검사에서 보류되던 3장 가운데 2장이 정답, 1장이 오판이 되었다. 따라서 이 자료에서 기하 검사의 기여는 작았으며, 배경이 다른 환경에서의 효과는 확인하지 못했다. 가장 좁은 판정 여유 ±2.22%를 식 (1)로 촬영 거리에 환산하면 약 33 mm이다. 이는 다른 오차를 제외한 일차 민감도이며, 실제 지그 허용 공차는 통제 실험으로 정해야 한다.

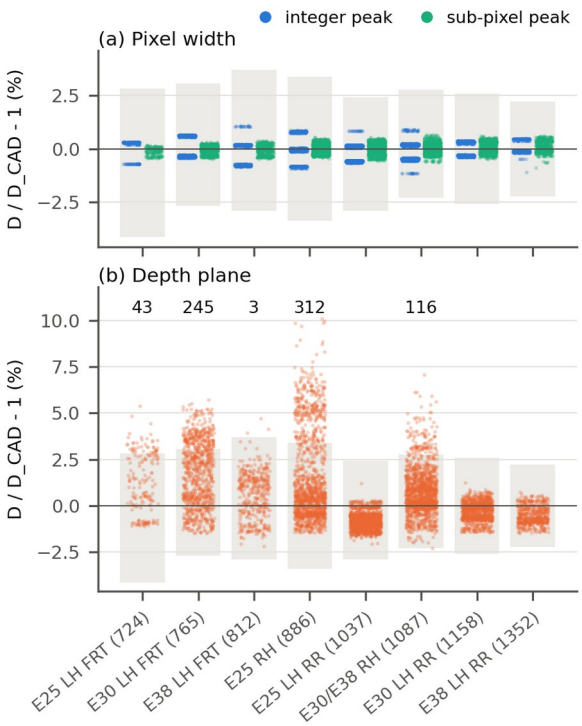


Fig. 3 Relative residual to CAD per class, five-fold out-of-fold test images (361 doors). (a) Pixel width with integer and sub-pixel heatmap peaks; (b) depth plane. Gray bars: decision margin of each class (Table 1); numbers: images outside the margin

Table 4 Distance representations with the same detectors (five-fold test images). Residuals are relative to the CAD value of the true class

Distance	Doors wrong / rejected	Residual range (%)	RMS (%)	Max. U
Pixel width, integer peak	0 / 0	−1.14 / +1.11	0.42	0.50
Pixel width, sub-pixel peak	0 / 0	−0.87 / +0.66	0.24	0.39
Depth plane	16 / 13	−2.29 / +10.08	1.77	2.43

4.4 미등록 형상군의 보류와 CAD 등록

공통 학습 조건. 이미 학습한 형상군을 목록에서 빼는 경우에는 두 방법 모두 미등록 도어를 보류하였다(Table 5). 다섯 폴드에서 홀 방법은 미등록 도어 361개를 모두 보류하고 등록 도어 판정 2,527건을 모두 맞혔다. 미등록 영상의 측정 D와 가장 가까운 등록값의 거리는 최소 37.4 mm였다. 출력을 가린 CNN은 네 점수 모두에서 360개를 보류하였고, 보류하지 못한 1개는 4.2절에서 E30 LH FRT로 오판된 E25 LH FRT 도어였다. CNN은 등록 도어 판정의 2.0~3.2%를 보류하였다.

공통 미학습 조건. 뺀 형상군을 학습에서 본 적이 없는 홀 검출기도 그 형상군의 공용 홀을 찾았다. 세 시드의 검출기 24개 모두에서 시험 그룹 현장 좌표 48점이 8화소 이내로 검출되었고, 그중 뺀 형상군의 영상에 찍은 점(시드마다 48점)의 오차도 중앙값 2.5화소, 최대 5.2화소였다. 홀 방법은 세 시드 모두에서 미등록 도어 74개(영상 1,478장)를 전부 보류하고 등록 도어 판정 518건을 모두 맞혔다(Table 6, Table 7). 미등록 영상의 측정 D와 가장 가까운 등록값의 거리는 세 시드를 통틀어 최소 36.9 mm였다.

CNN의 결과는 점수에 따라 달랐다. 출력에 기반한 세 점수(소프트맥스, 최대 로짓, 에너지)는 시드와 입력에 따라 74개 중 42~55개만 보류하였다. 보류하지 못한 도어는 모두 같은 위치의 다른 기종 형상군으로 수락되었고(E38 LH FRT → E30 LH FRT, E30/E38 RH → E25 RH 등), 그 두 형상군의 CAD D는 41~201 mm 다르다. 특히 E25 LH FRT, E38 LH FRT, E30/E38 RH의 미등록 도어 21개는 이 세 점수로는 어느 시드에서도 3개까지만 보류되었다. 단정밀도 소프트맥스로 계산해도 보류 수의 차이는 1개 이내였으므로, 이 결과는 점수의 포화 때문이 아니다. 반면 마할라노비스 점수는 RGB CNN에서 세 시드 모두 74개를 전부 보류하였고, RGBE CNN에서는 두 시드에서 74개, 한 시드에서 69개를 보류하였다(E38 LH FRT 도어 5개를 E30 LH FRT로 수락). 따라서 외관 CNN이 학습하지 않은 형상군을 보류하지 못한다는 것은 출력 기반 점수에 한정된 결과이며, 특징 거리 점수를 쓰면 CNN도 미등록 도어를 대부분 보류한다.

두 방법의 차이는 등록 도어에서 나타났다. 마할라노비스 점수의 CNN은 등록 도어 판정 518건 중 33~45건(6.4~8.7%)을 보류하였고, 홀 방법은 세 시드 모두 보류가 없었다. 영상 단위 AUROC도 홀 방법은 1.000(최솟값 0.999, 한 시드에서 등록 영상 1장이 측정되지 않음)이었고, 마할라노비스 점수는 평균 0.962~0.987(최솟값 0.778)이었다. 8개 형상군을 모두 학습한 CNN에서도 마할라노비스 임계값은 시간 분할의 도어 5~8개를 보류하였다(Table 5). 다만 두 방법의 보류 기준은 정하는 방식이 다르다. CNN의 임계값은 검증 영상의 5%를 보류하도록 정한 값이고 홀 방법의 30 mm는 고정값이므로, 등록 도어의 보류 수는 임계값을 달리 정하면 달라진다. 임계값과 무관한 비교는 AUROC이다.

CAD 등록. 미학습 조건의 검출기와 S를 그대로 두고 뺀 형상군의 CAD 값만 목록에 다시 넣자, 세 시드 모두에서 그 형상군의 도어 74개(Wilson 95% 구간 95.1~100%)와 영상 1,478장이 전부 올바르게 식별되었고, 다른 형상군의 도어 판정 518건도 모두 그대로였다. U의 최댓값은 시드별로 0.50, 0.50, 0.53이었다. 뺀 형상군 없이 정한 S는 1,472.5~1,475.7 mm로, 같은 폴드에서 모든 형상군으로 정한 값(1,475.3 mm)과의 차가 0.2% 이내였다. 즉 검출기와 축척이 한 번도 보지 못한 형상군이라도 같은 홀 배치를 공유하면 CAD 값 하나로 식별되었다. 출력이 고정된 CNN은 특징 거리 점수로 그 도어를 보류할 수는 있어도 재학습 없이는 그 형상군의 이름을 낼 수 없다. 이 결과는 형상군별 도어 2~14개에서 얻은 것이다.

E23 LH FRT. 대상 밖 형상군인 E23 도어 6개(120장)는 어느 검출기의 학습에도 없었다. 홀 방법은 120장을 모두 보류하였고(측정 D 중앙값 454 mm, 가장 가까운 등록값과의 차 266 mm), 검출기와 S를 그대로 둔 채 CAD 값 458 mm만 등록하자 120장과 6개 도어가 모두 E23으로 판정되었다. 두 CNN도 네 점수 모두에서 E23 도어 6개를 보류하였다. 6/6의 Wilson 95% 하한은 61.0%이다.

Table 5 Seen-class condition (five folds, CNN output masked) and operating points on registered doors at each score's validation threshold, seed 42. Unreg.: unregistered doors rejected (of 361); Reg.: registered-door decisions rejected / wrong (of 2,527); c / r / w: doors correct / rejected / wrong. The max-logit and energy scores gave the same counts in every column

Method, score	Unreg.	Reg.	Five-fold c / r / w	Temporal c / r / w
Hole	361	0 / 0	361 / 0 / 0	133 / 0 / 0
RGB, softmax	360	79 / 6	349 / 11 / 1	105 / 28 / 0
RGB, max logit, energy	360	66 / 6	351 / 9 / 1	114 / 18 / 1
RGB, Mahalanobis	360	68 / 6	351 / 9 / 1	124 / 8 / 1
RGBE, softmax	360	59 / 6	353 / 7 / 1	111 / 21 / 1
RGBE, max logit, energy	360	50 / 6	352 / 8 / 1	117 / 15 / 1
RGBE, Mahalanobis	360	82 / 6	348 / 12 / 1	127 / 5 / 1

Table 6 Unseen-class condition, seed 42 (fold 0): doors of the removed class rejected while unregistered and, for the hole method, identified after only the CAD value was registered. Parentheses: smallest distance (mm) to a registered CAD value (hole) or the accepting class (CNN). Max-logit and energy scores gave the same door counts as softmax; the Mahalanobis score rejected all doors. E23: eight-class models

Removed class	Doors	Hole rejected / identified	RGB CNN, softmax	RGBE CNN, softmax
E25 LH FRT	2	2 / 2 (38.7)	0 (E30 LH FRT)	0 (E30 LH FRT)
E30 LH FRT	9	9 / 9 (38.4)	9	9
E38 LH FRT	5	5 / 5 (41.2)	0 (E30 LH FRT)	0 (E30 LH FRT)
E25 RH	14	14 / 14 (65.4)	14	14
E25 LH RR	14	14 / 14 (47.9)	14	14
E30/E38 RH	14	14 / 14 (37.6)	0 (E25 RH)	0 (E25 RH)
E30 LH RR	10	10 / 10 (67.7)	10	10
E38 LH RR	6	6 / 6 (192.6)	0 (E30 LH RR)	6
Total	74	74 / 74	47	53
E23 LH FRT	6	6 / 6 (266.5)	6	6

Table 7 Unseen-class condition over three training seeds (42 / 123 / 456; fold 0; 74 unregistered doors and 518 registered-door decisions per seed). No registered door was identified wrongly. AUROC: mean over the eight runs of a seed, range over seeds; parentheses: smallest run value. The max-logit and energy scores gave the same counts and, to three decimals, the same AUROC

Method, score	Unregistered rejected (of 74)	Registered rejected (of 518)	AUROC mean (min)
Hole	74 / 74 / 74	0 / 0 / 0	1.000 (0.999)
RGB, softmax	47 / 53 / 53	20 / 18 / 19	0.772–0.813 (0.047)
RGB, max logit, energy	47 / 55 / 52	19 / 17 / 16	0.788–0.841 (0.245)
RGB, Mahalanobis	74 / 74 / 74	39 / 38 / 44	0.974–0.977 (0.903)
RGBE, softmax	53 / 49 / 49	10 / 19 / 24	0.722–0.773 (0.007)
RGBE, max logit, energy	53 / 49 / 42	7 / 21 / 14	0.697–0.732 (0.003)
RGBE, Mahalanobis	74 / 69 / 74	36 / 33 / 45	0.962–0.987 (0.778)

4.5 한계

본 연구의 데이터는 한 사업장의 고정 지그와 카메라 한 대에서 수집되었고, 평가는 후향적이다. 정답은 작업자 입력을 저자 1인이 영상으로 확인한 것이며 (CNN이 다르게 판정한 도어 2개 포함), 실물 측정이나 독립된 제2 확인자의 검증은 없다. 미학습 조건은 폴드 0에서만 평가하였고 형상군별 미등록 도어는 2~14개이다. 세 시드는 학습의 반복이며 도어가 늘어난 것은 아니다. E25 LH FRT와 E23 LH FRT는 도어가 각각 9개와 6개로 적다. 학습을 쓰지 않는 고전적 홀 검출 기준선과 개방 집합 CNN은 비교하지 않았다. 현장 좌표의 필요량은 이 현장에서 확인한 것이며 다른 지그·조명·카메라에서는 따로 검증해야 한다. 거리의 기준은 실물 실측값이 아니라 CAD 값이다. 픽셀 폭 방식은 촬영 거리가 일정하다는 전제에 의존하므로, 거리가 변하는 셀에서는 볼트 홀 피치 등을 이용한 영상별 축척 추정이 필요하다. 판정이 거리 D 하나에 의존하므로 D가 같거나 30 mm 이내로 가까운 형상군은 구분할 수 없고, 그런 형상군이 미등록이면 기존 형상군으로 수락된다. 새 형상군을 등록할 때에는 CAD 값의 간격과 측정 잔차를 함께 검토해야 하며, 간격이 충분하지 않으면 다른 특징이 필요하다.

5. 결 론

굴착기 측면 도어 8 개 형상군의 식별에서, 모든 형상군에 공통인 홀 6 점의 검출 가중치와 형상군별 CAD 거리 목록을 분리한 구조를 한 사업장의 고정 지그에서 수집한 실제 생산 도어 361 개로 후향적으로 평가하였다. 실험실 영상만으로 학습한 검출기는 현장의 모서리 홀을 찾지 못했으나, 폴드마다 현장 영상 8 장을 학습에 더하고 8 장으로 모델을 선택하자 5 겹 교차검증의 도어 361 개를 모두 식별하였고, 이전 기간의 현장 영상 24 장으로 학습한 모델은 이후 기간의 도어 133 개를 모두 식별하였다. 외관 CNN 도 361 개 중 360 개와 359 개를 맞혀, 등록된 형상군만 입력되는 조건의 정확도에서는 우월성을 확인하지 못했다.

식별을 거리 측정으로 바꾸자 판정의 근거를 물리 단위의 판정 여유로 진단할 수 있었다. 픽셀 폭 거리는 측정 가능한 모든 시험 영상의 잔차가 판정 여유 안에 있었고, 도어 단위로는 여유의 절반 이하만 사용하였다. 깊이 평면 거리는 일부 도어에서 거리를 크게 재는 치우침으로 판정 여유를 넘어 오분류와 보류를 만들었다. 부화소 보간은 잔차의 RMS 를 0.42%에서 0.24%로 줄였다.

판정 목록이 검출 가중치 밖에 있으므로 형상군의 등록은 목록의 변경으로 이루어졌다. 8 개 형상군을 하나씩 모든 학습에서 뺀 실험에서, 홀 방법은 세 시드 모두 그 형상군의 도어 74 개를 미등록 상태에서 전부 보류하였고, CAD 값만 등록하자 74 개를 전부 식별하였다. 대상 밖의 E23 도어 6 개에서도 같은 결과를 얻었다. 외관 CNN 은 소프트맥스·로짓·에너지 점수로는 74 개 중 42~55 개만 보류하였으나 마할라노비스 점수로는 69~74 개를 보류하였으므로, 미등록 형상군의 보류는 제안 방법만의 성질이 아니다. 차이는 두 가지이다. 검증 영상의 95%를 수락하도록 정한 임계값에서 마할라노비스 점수의 CNN 은 등록 도어 판정의 6~9%를 함께 보류하였고, 30 mm 기준이 고정된 홀 방법은 보류가 없었다(임계값과 무관한 영상 단위 AUROC 는 0.962~0.987 대 1.000). 그리고 홀 방법은 재학습 없이 CAD 값만으로 새 형상군을 식별한다.

이 결과는 판정 근거의 추적과 형상군 목록의 운용이 필요한 고정 지그 공정에서 홀 랜드마크와 CAD 치수 대조가 외관 분류기의 실용적인 대안 또는 보완이 될 수 있음을 보여 준다. 결과는 한 현장과 카메라 한 대에서 얻은 것이며, 다른 지그에서 필요한 현장 주석량, 지그 위치 공차의 통제 실험, 실측 기준의 거리 검증, 임베디드 장치에서의 처리 시간, 고전적 홀 검출 및 개방 집합 CNN 과의 비교는 후속 과제이다.

References

[1] He, K., Zhang, X., Ren, S., Sun, J., 2016, Deep Residual Learning for Image Recognition, Proc. IEEE Conf. Comput. Vis. Pattern Recognit. 770-778.

[2] Prünte, P., Schoepflin, D., Schüppstuhl, T., 2023, A Comparative Study of Visual Identification Methods for Highly Similar Engine Tubes in Aircraft Maintenance, Repair and Overhaul, Sensors 23:15 6779, https://doi.org/10.3390/s23156779.

[3] Scheirer, W. J., de Rezende Rocha, A., Sapkota, A., Boult, T. E., 2013, Toward Open Set Recognition, IEEE Trans. Pattern Anal. Mach. Intell. 35:7 1757-1772, https://doi.org/10.1109/TPAMI.2012.256.

[4] Hendrycks, D., Gimpel, K., 2017, A Baseline for Detecting Misclassified and Out-of-Distribution Examples in Neural Networks, Proc. Int. Conf. Learn. Represent.

[5] Hendrycks, D., Basart, S., Mazeika, M., Zou, A., Kwon, J., Mostajabi, M., Steinhardt, J., Song, D., 2022, Scaling Out-of-Distribution Detection for Real-World Settings, Proc. Int. Conf. Mach. Learn. 8759-8773.

[6] Liu, W., Wang, X., Owens, J., Li, Y., 2020, Energy-based Out-of-distribution Detection, Adv. Neural Inf. Process. Syst. 33 21464-21475.

[7] Lee, K., Lee, K., Lee, H., Shin, J., 2018, A Simple Unified Framework for Detecting Out-of-Distribution Samples and Adversarial Attacks, Adv. Neural Inf. Process. Syst. 31 7167-7177.

[8] Lamdan, Y., Wolfson, H. J., 1988, Geometric Hashing: A General and Efficient Model-Based Recognition Scheme, Proc. Int. Conf. Comput. Vis. 238-249.

[9] Lampert, C. H., Nickisch, H., Harmeling, S., 2009, Learning to Detect Unseen Object Classes by Between-Class Attribute Transfer, Proc. IEEE Conf. Comput. Vis. Pattern Recognit. 951-958.

[10] Behnen, H., Boada-Gardenyes, G., Schmitt, R. H., Teschner, M., Pönitz, W., Weiß, K., 2026, Sheet Metal Localization Using Deep Learning and Synthetic Data, J. Intell. Manuf. 37 399-415, https://doi.org/10.1007/s10845-024-02552-7.

[11] Lin, S., Xiao, S., Lin, R., Wu, J., Luo, W., 2026, Multi-feature Dimension Measurement Method for Sheet Metal Parts Based on PRT Files and Machine Vision, Measurement 258 119276, https://doi.org/10.1016/j.measurement.2025.119276.

[12] Lin, T.-Y., Dollár, P., Girshick, R., He, K., Hariharan, B., Belongie, S., 2017, Feature Pyramid Networks for Object Detection, Proc. IEEE Conf. Comput. Vis. Pattern Recognit. 2117-2125.

[13] Xiao, B., Wu, H., Wei, Y., 2018, Simple Baselines for Human Pose Estimation and Tracking, Proc. Eur. Conf. Comput. Vis. 466-481.